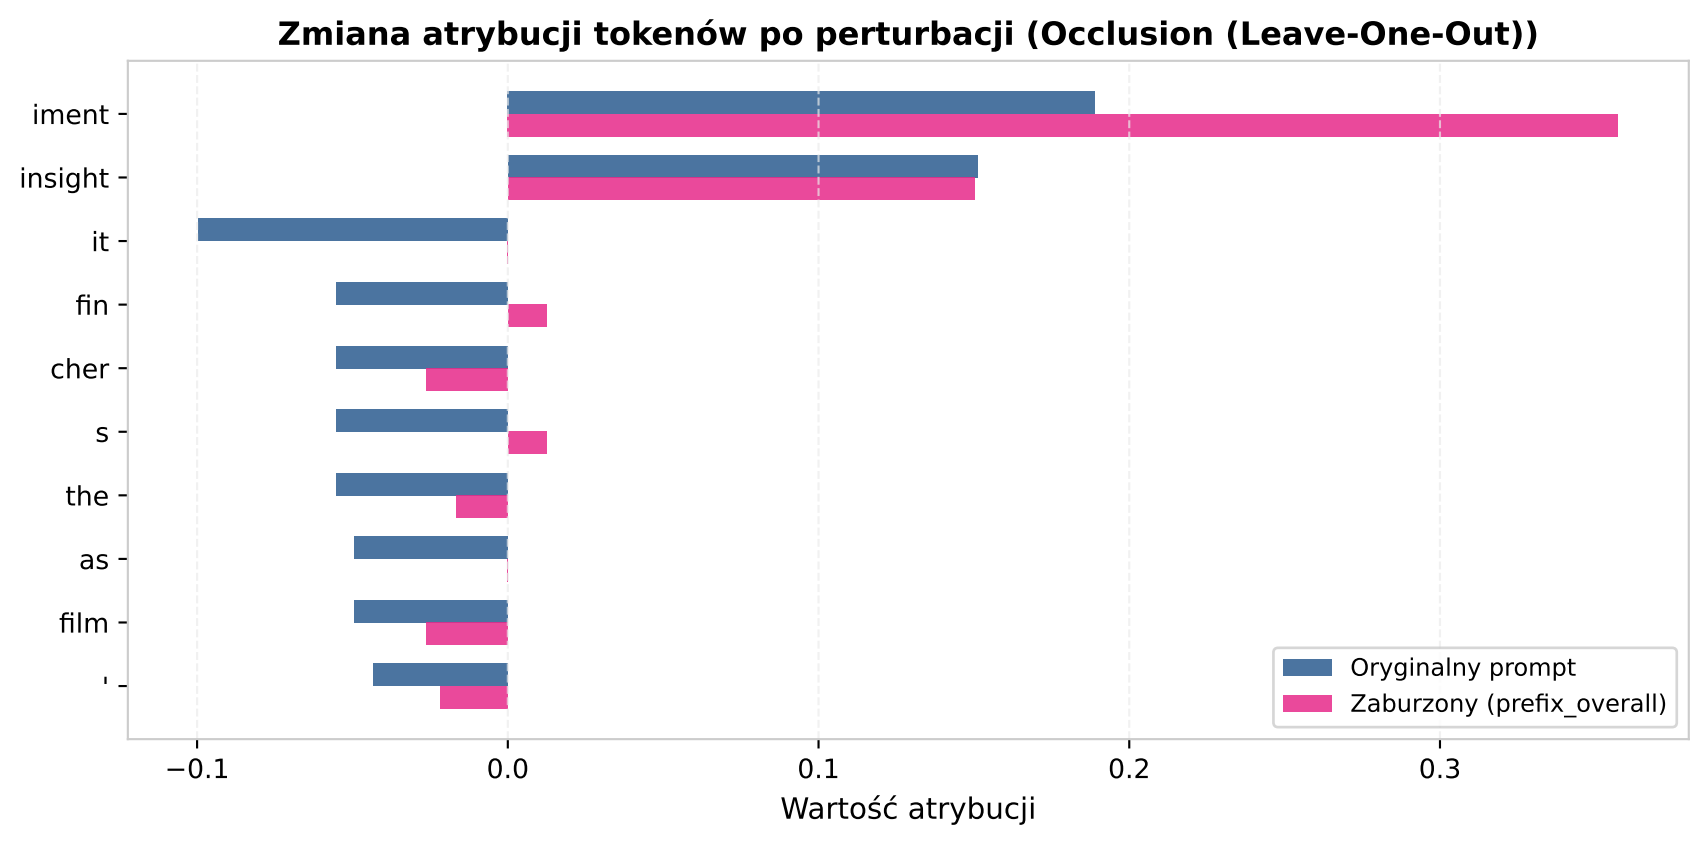
Zmiana atrybucji tokenów po perturbacji (Occlusion (Leave-One-Out))
iment
insight
it
fin
cher
s
the
as
film
'
Oryginalny prompt
Zaburzony (prefix_overall)
−0.1
0.0
0.1
0.2
0.3
Wartość atrybucji